

# PREDICION DE PUNTOS CLAVE DEL ROSTRO

Buscamos un modelo que pueda predecir si un paciente es un paciente Parkinson o un paciente control por medio de los puntos clave del rostro.

**Faiber Stiven Angarita**

Proyecto final

# MOTIVACION



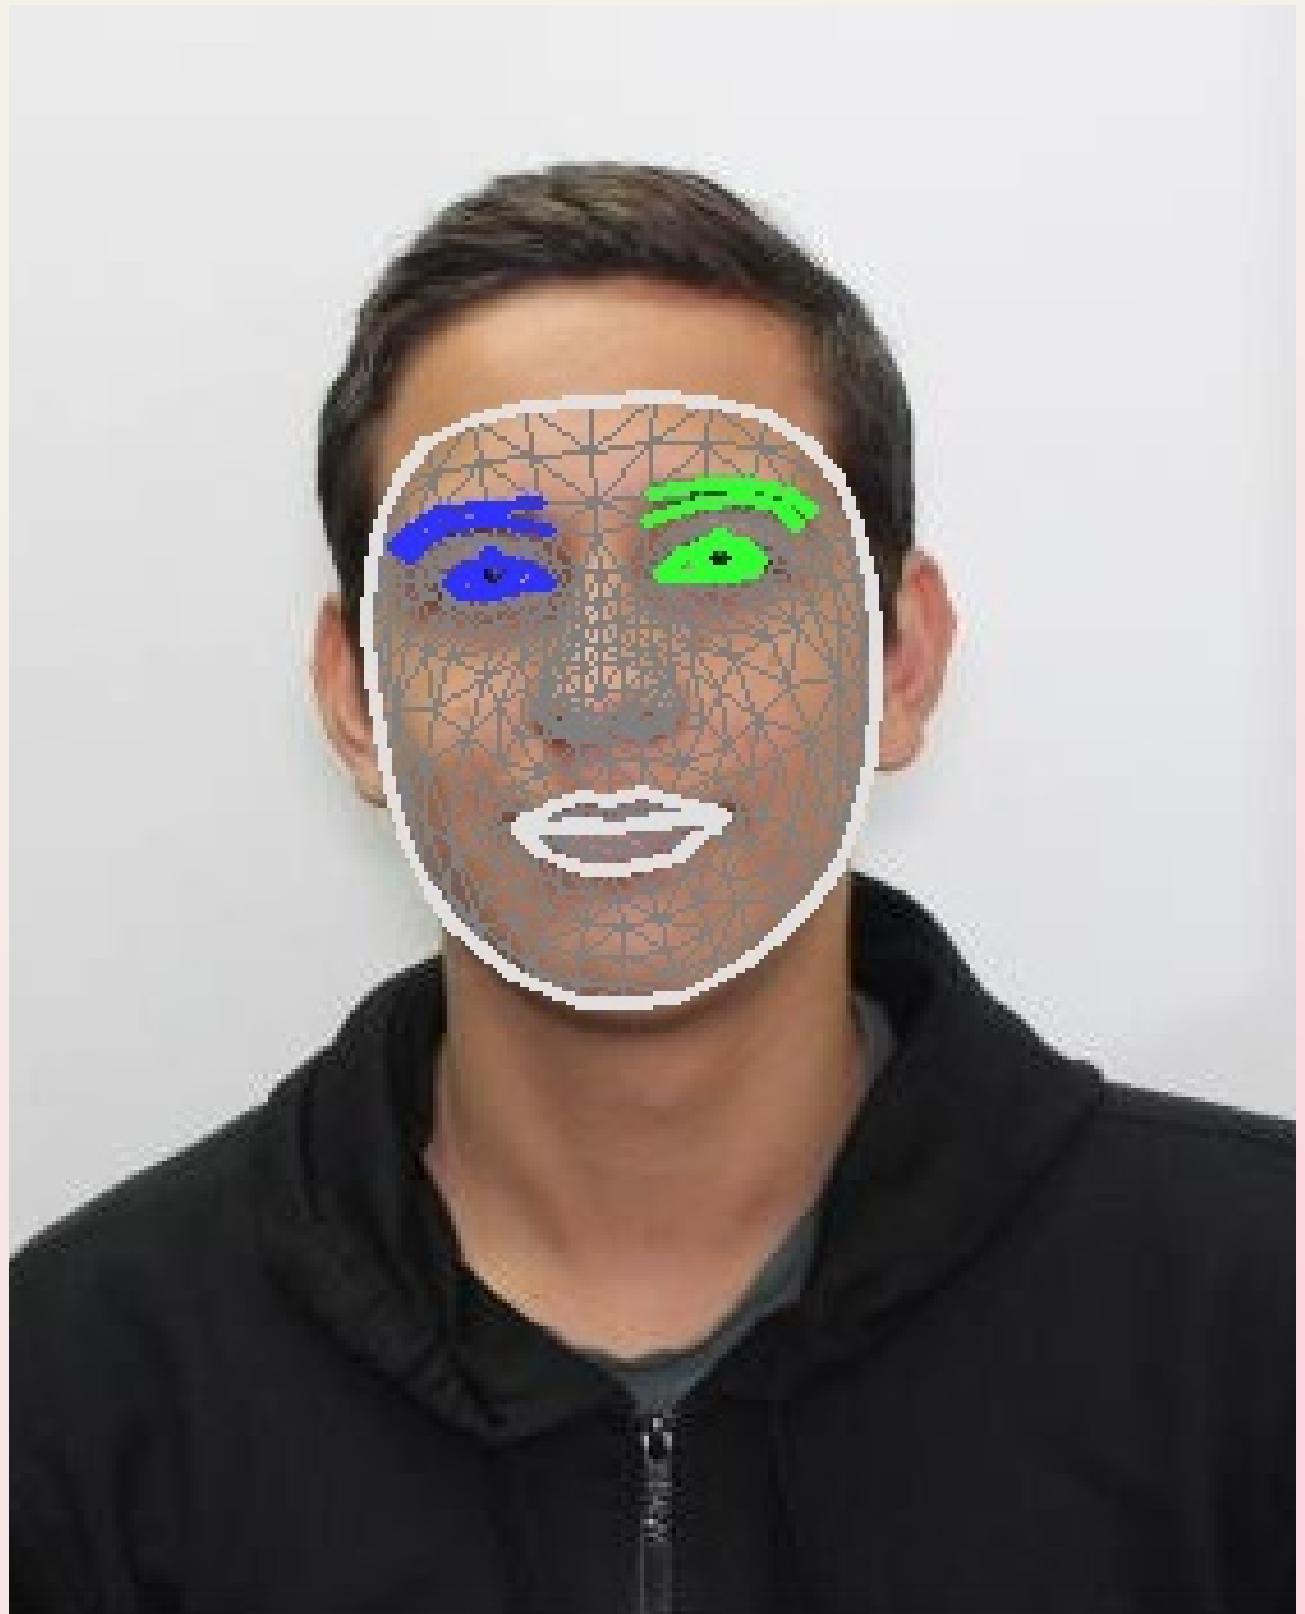
- Importancia de la detección temprana del Parkinson
- Potencialidad de la inteligencia artificial en el diagnóstico médico
- Contribución en la investigación del Parkinson

# ¿CUAL ES EL PROBLEMA?

Diagnóstico por medio de los puntos clave del rostro, detectando anomalías en los movimientos al pronunciar palabras.

## OBJETIVO

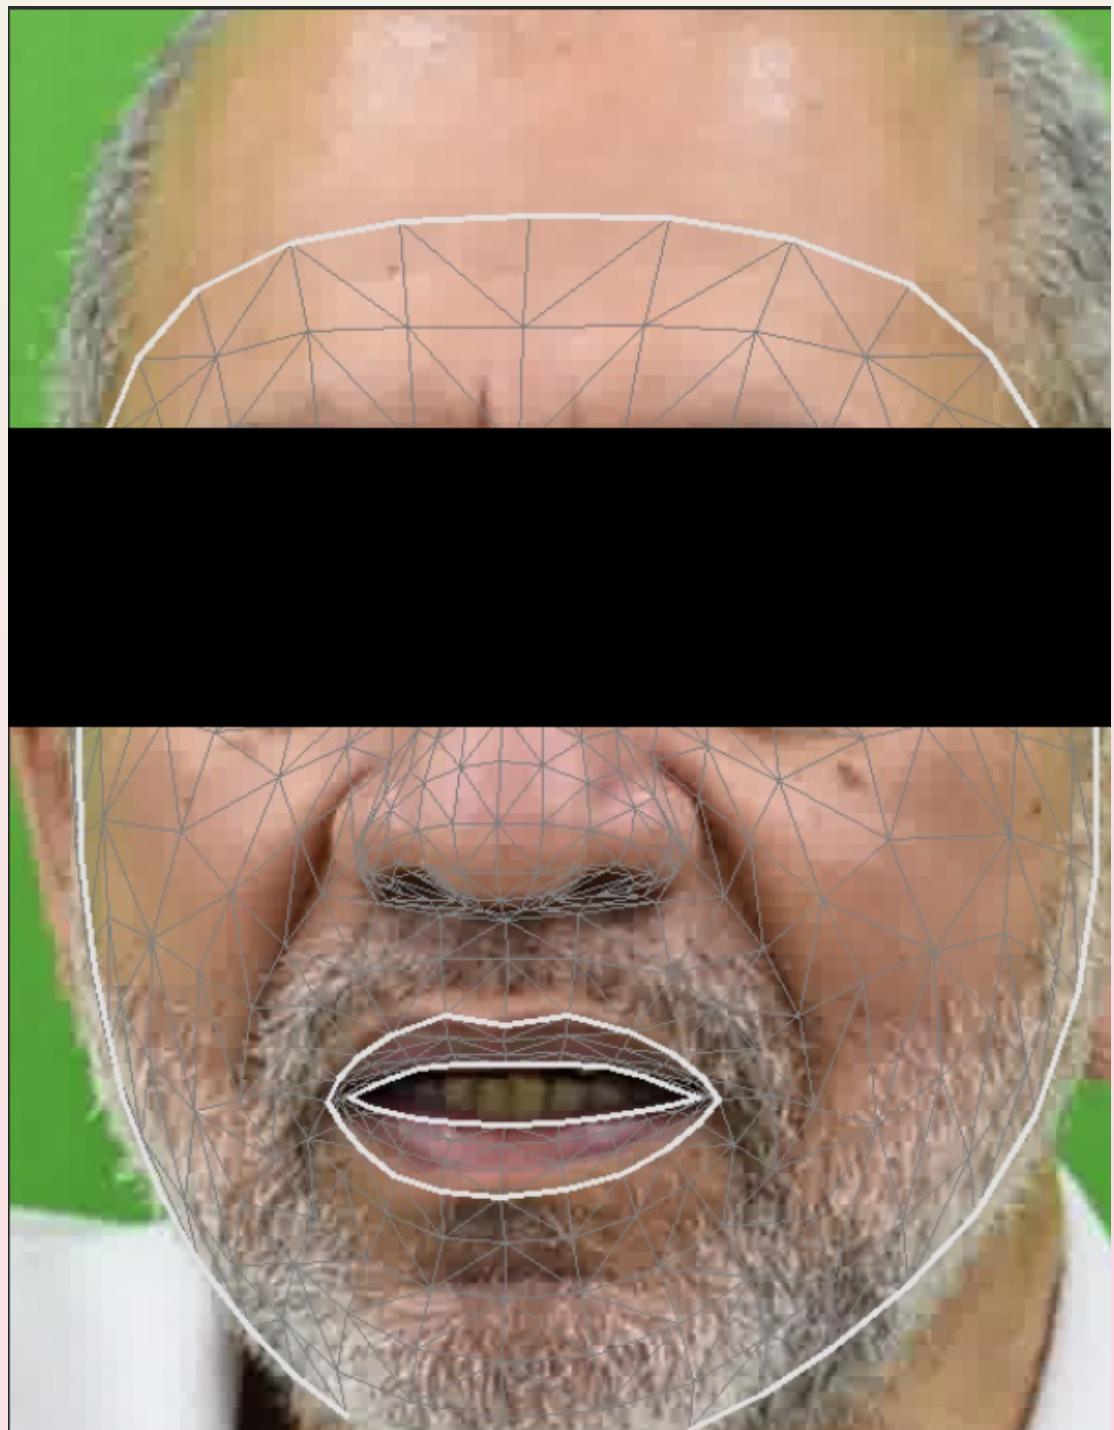
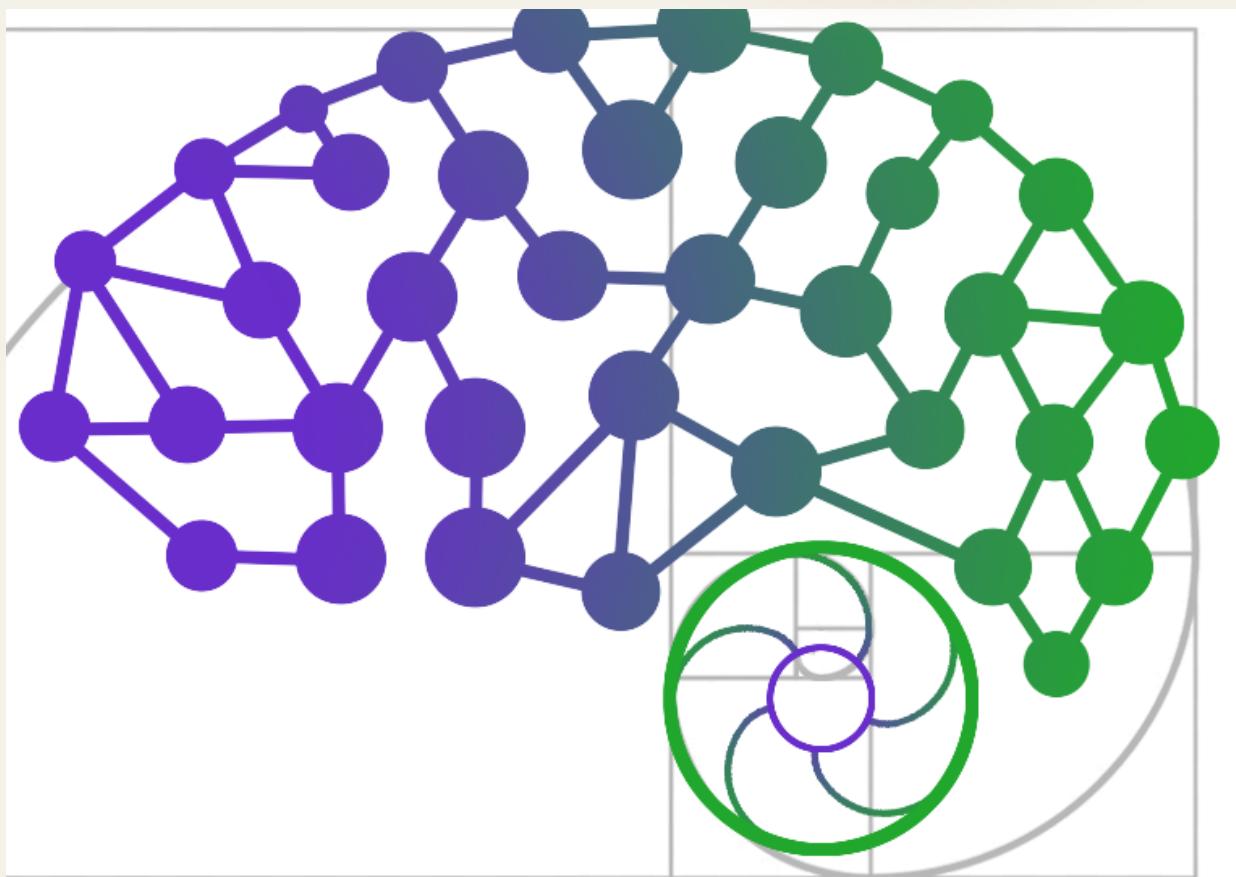
El objetivo de nuestro proyecto es hallar los puntos clave del rostro para cada paciente y clasificarlo como Parkinson o Control



# DATASET

EL DATASET ESTA CONSTRUIDO POR DOS CLASES DE PACIENTES  
7 PACIENTES CONTROL  
7 PARKINSON

- MAS DE 1000 VIDEOS EN TOTAL
- 3 DIFERENTES MODALIDADES



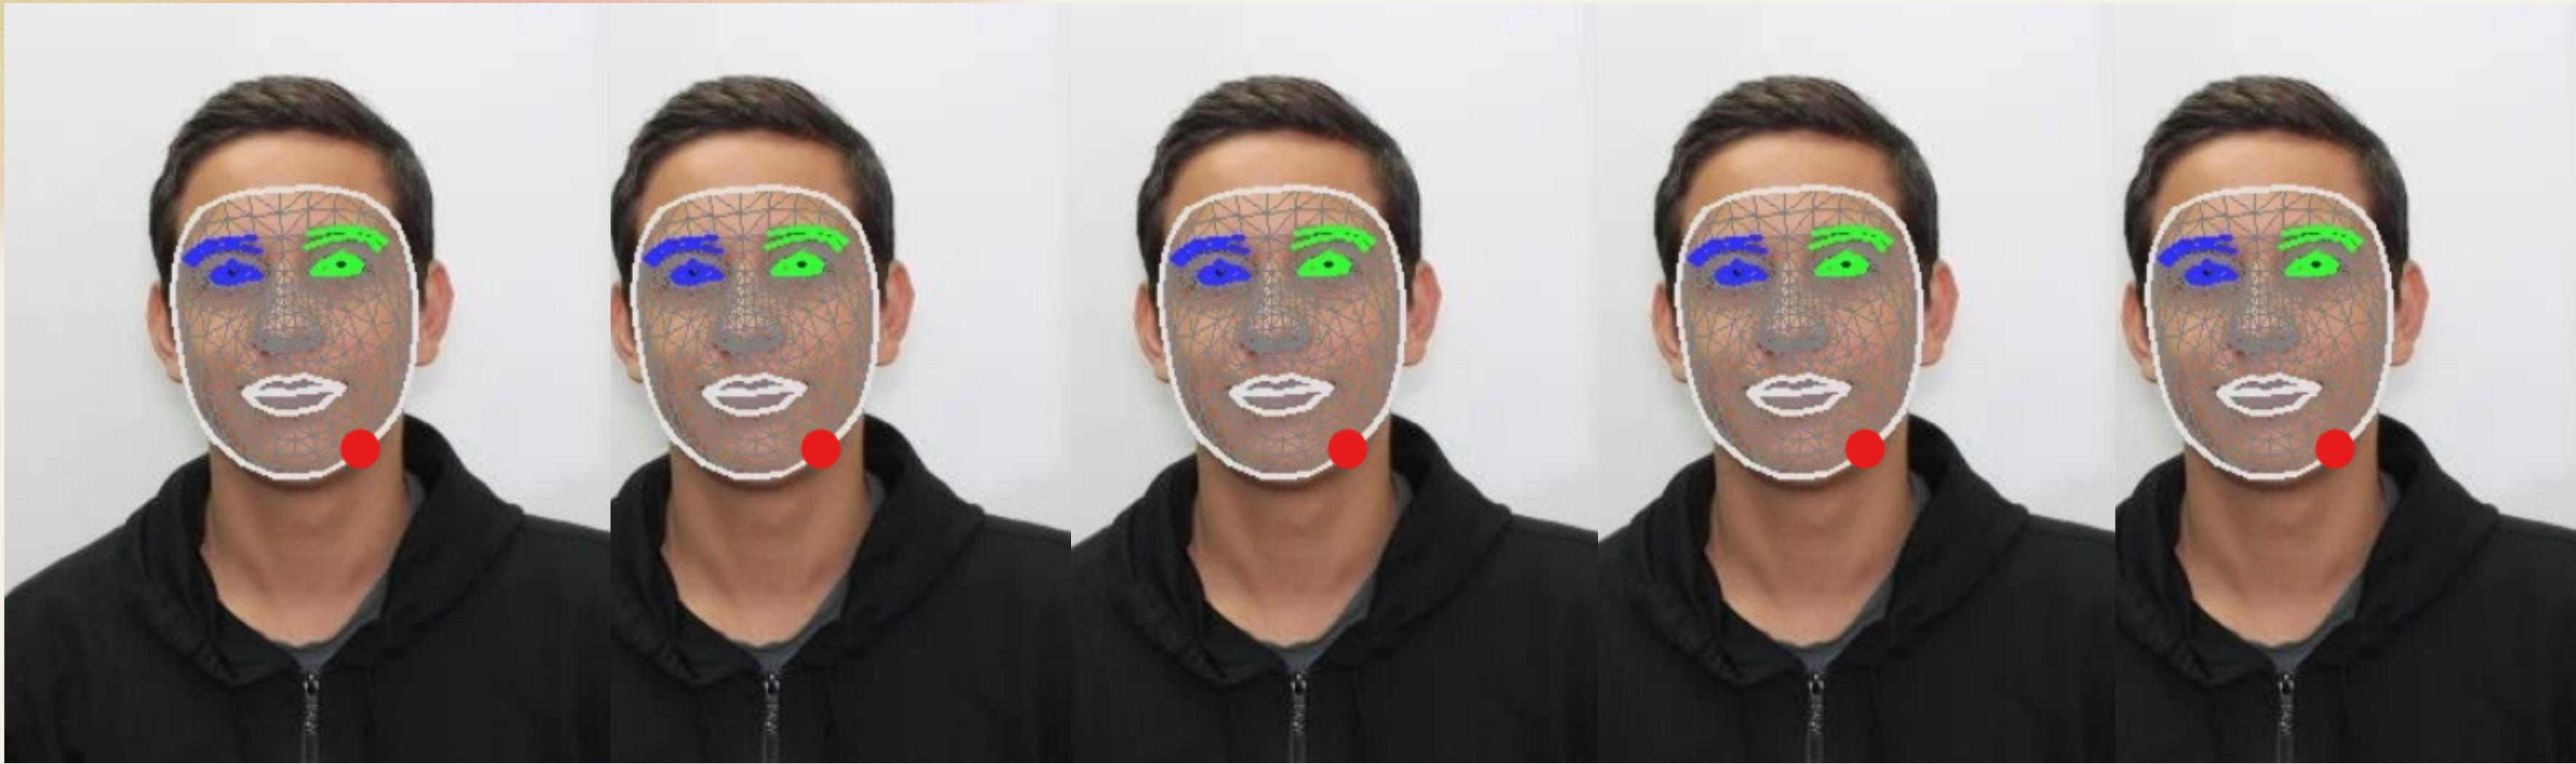
# MÉTODO

## Extraer los puntos

Existen diferentes frameworks que nos ayudan a extraer los puntos clave del rostro, como por ejemplo Openpose, Opencv, FaceMesh y Mediapipe.

## Preprocesarlos e ingresarlos a una red neuronal

- Antes de extraer los puntos es necesario balancearlos datos y eliminar el ruido.
- Despues de extraer los datos se utilizan tecnicas de preprocesamiento como One-Hot Encoding

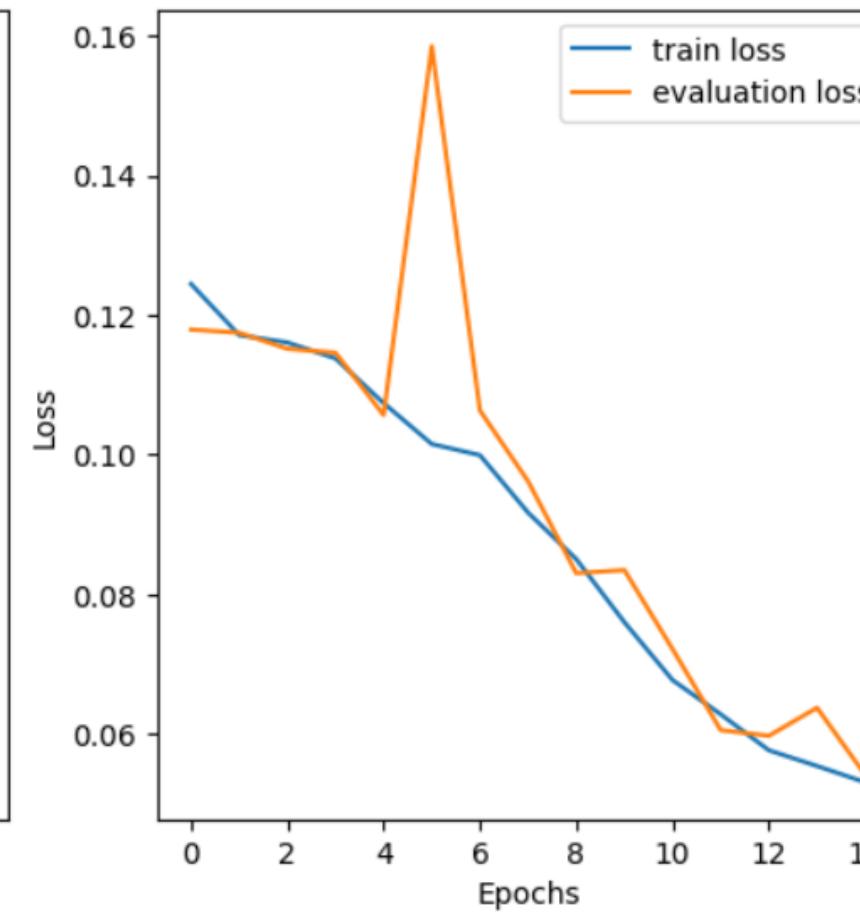
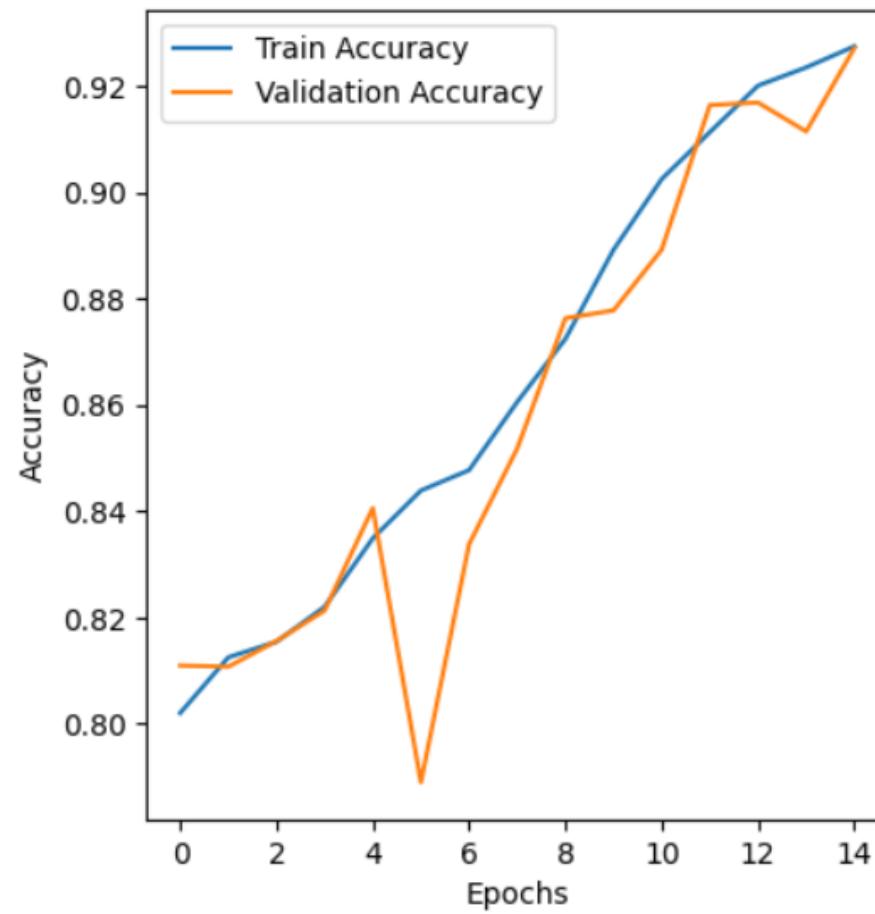


```
[0.51189935 0.51574552 0.51946819 0.51791012 0.51675707 0.51733607  
 0.51590359 0.51606125 0.5163691 0.51577252 0.51771176 0.51616913  
 0.51696831 0.51960409 0.51557213 0.51563883 0.51884854 0.51553971  
 0.51876777 0.51843327 0.51765788 0.52236199 0.51574707 0.51766145  
 0.5223586 0.52135187 0.51710987 0.52040744 0.51458538 0.52257633  
 0.52316147 0.51877266 0.52360964 0.52259147 0.52488333 0.5172599  
 0.52484393 0.52445275 0.5192892 0.52641958 0.52225411 0.5241785  
 0.52684242 0.52545327 0.52154988 0.52867591 0.51910347 0.5191288  
 0.51876324 0.51849681 0.5174036 0.52131093 0.51697224 0.51874173  
 0.5160411 0.51768899 0.51751274 0.5165565 0.51775241 0.52040511  
 0.51559812 0.51707536 0.51831329 0.51578647 0.51723367 0.51519042  
 0.51160944 0.51575124 0.51490074 0.5139727 0.51920736 0.51260895  
 0.51576751 0.5146156 0.5153771 ]
```

# RESULTADOS

- Se entrenaron 12 modelos
- Variando los hiperparametros como Loss, Learning rate, tamaño de batch, optimizador, epochas...

El mejor accuracy obtenido por un modelo es del 93% de accuracy en validación.



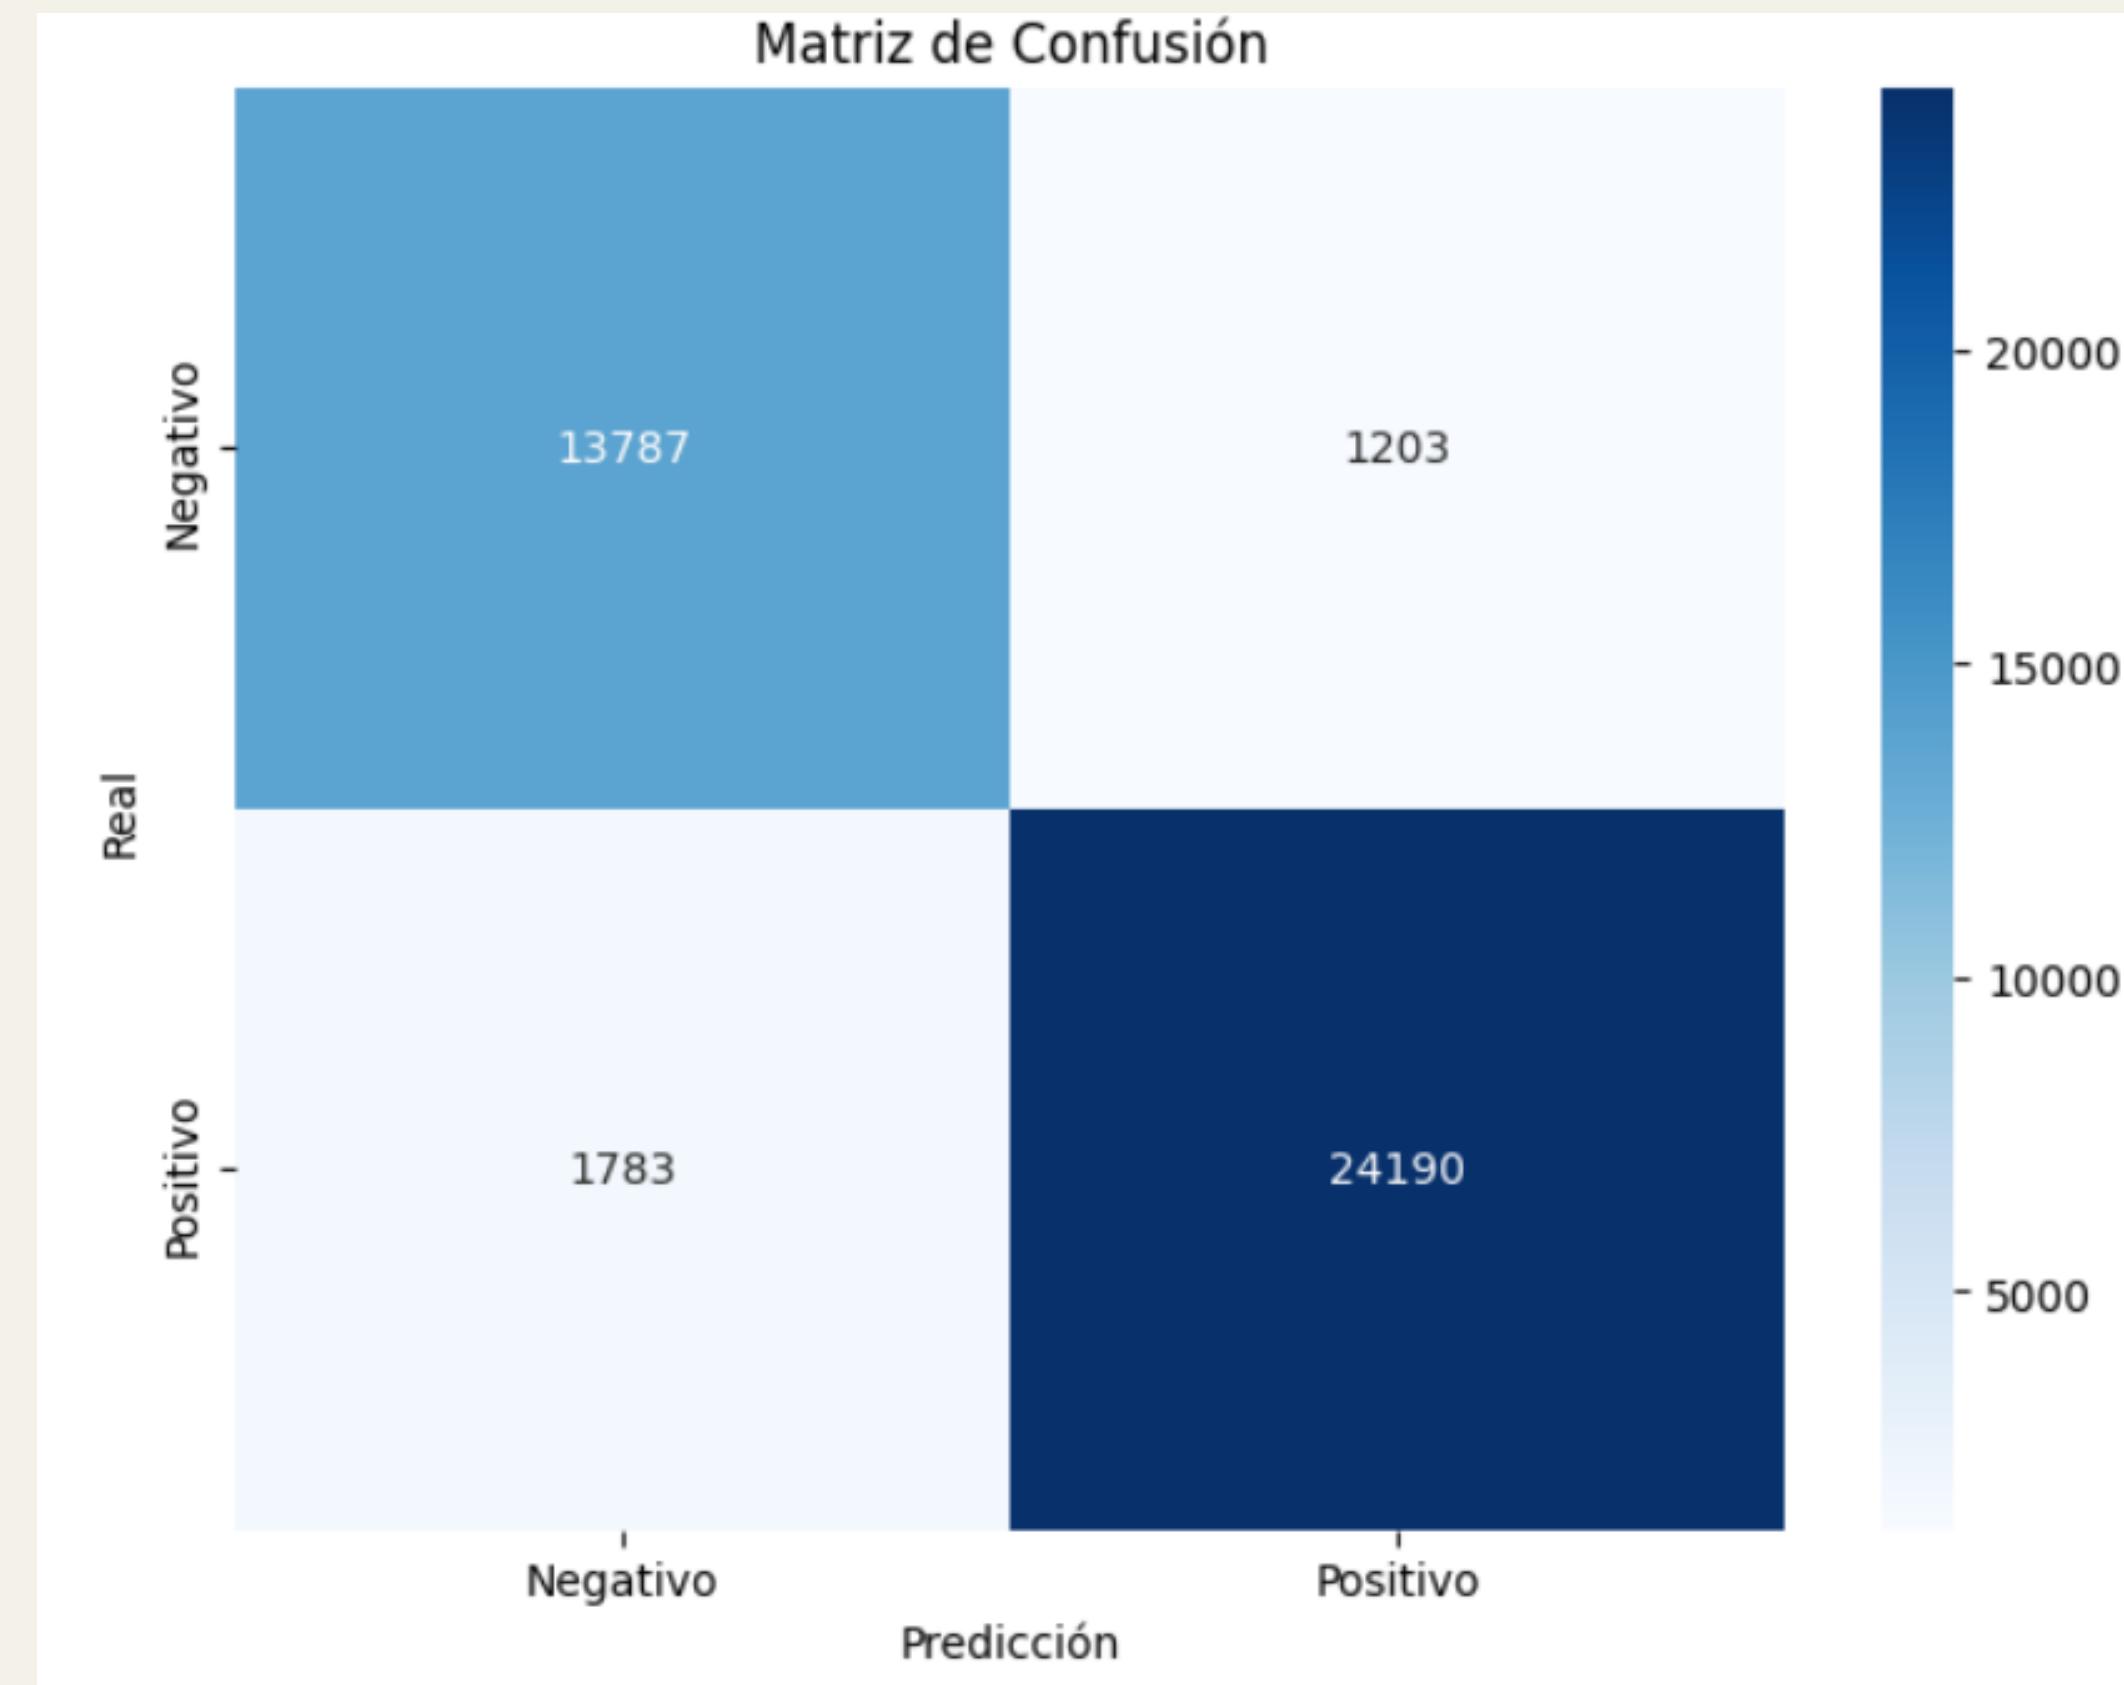
Model: "sequential\_13"

Layer (type)	Output Shape	Param #
dense_91 (Dense)	(None, 468)	258804
dense_92 (Dense)	(None, 256)	120064
dense_93 (Dense)	(None, 128)	32896
dense_94 (Dense)	(None, 64)	8256
dense_95 (Dense)	(None, 32)	2080
dense_96 (Dense)	(None, 16)	528
dense_97 (Dense)	(None, 1)	17
<hr/>		
Total params: 422645 (1.61 MB)		
Trainable params: 422645 (1.61 MB)		
Non-trainable params: 0 (0.00 Byte)		

# DETALLES DE LA MEJOR RED

- 7 capas
- Optimizador Adam
- Momentum 0.9
- Funcion de perdida mean squared error
- learning rate scheduler de  $0.001 \cdot e^{-0.1}$
- Early stoping
- Epocas 15
- tamaño de batch 468
- Accuracy 93%
- Precision de 95,26%
- Recall de 93,13
- F1-score de 93%

# MATRIZ DE CONFUSIÓN

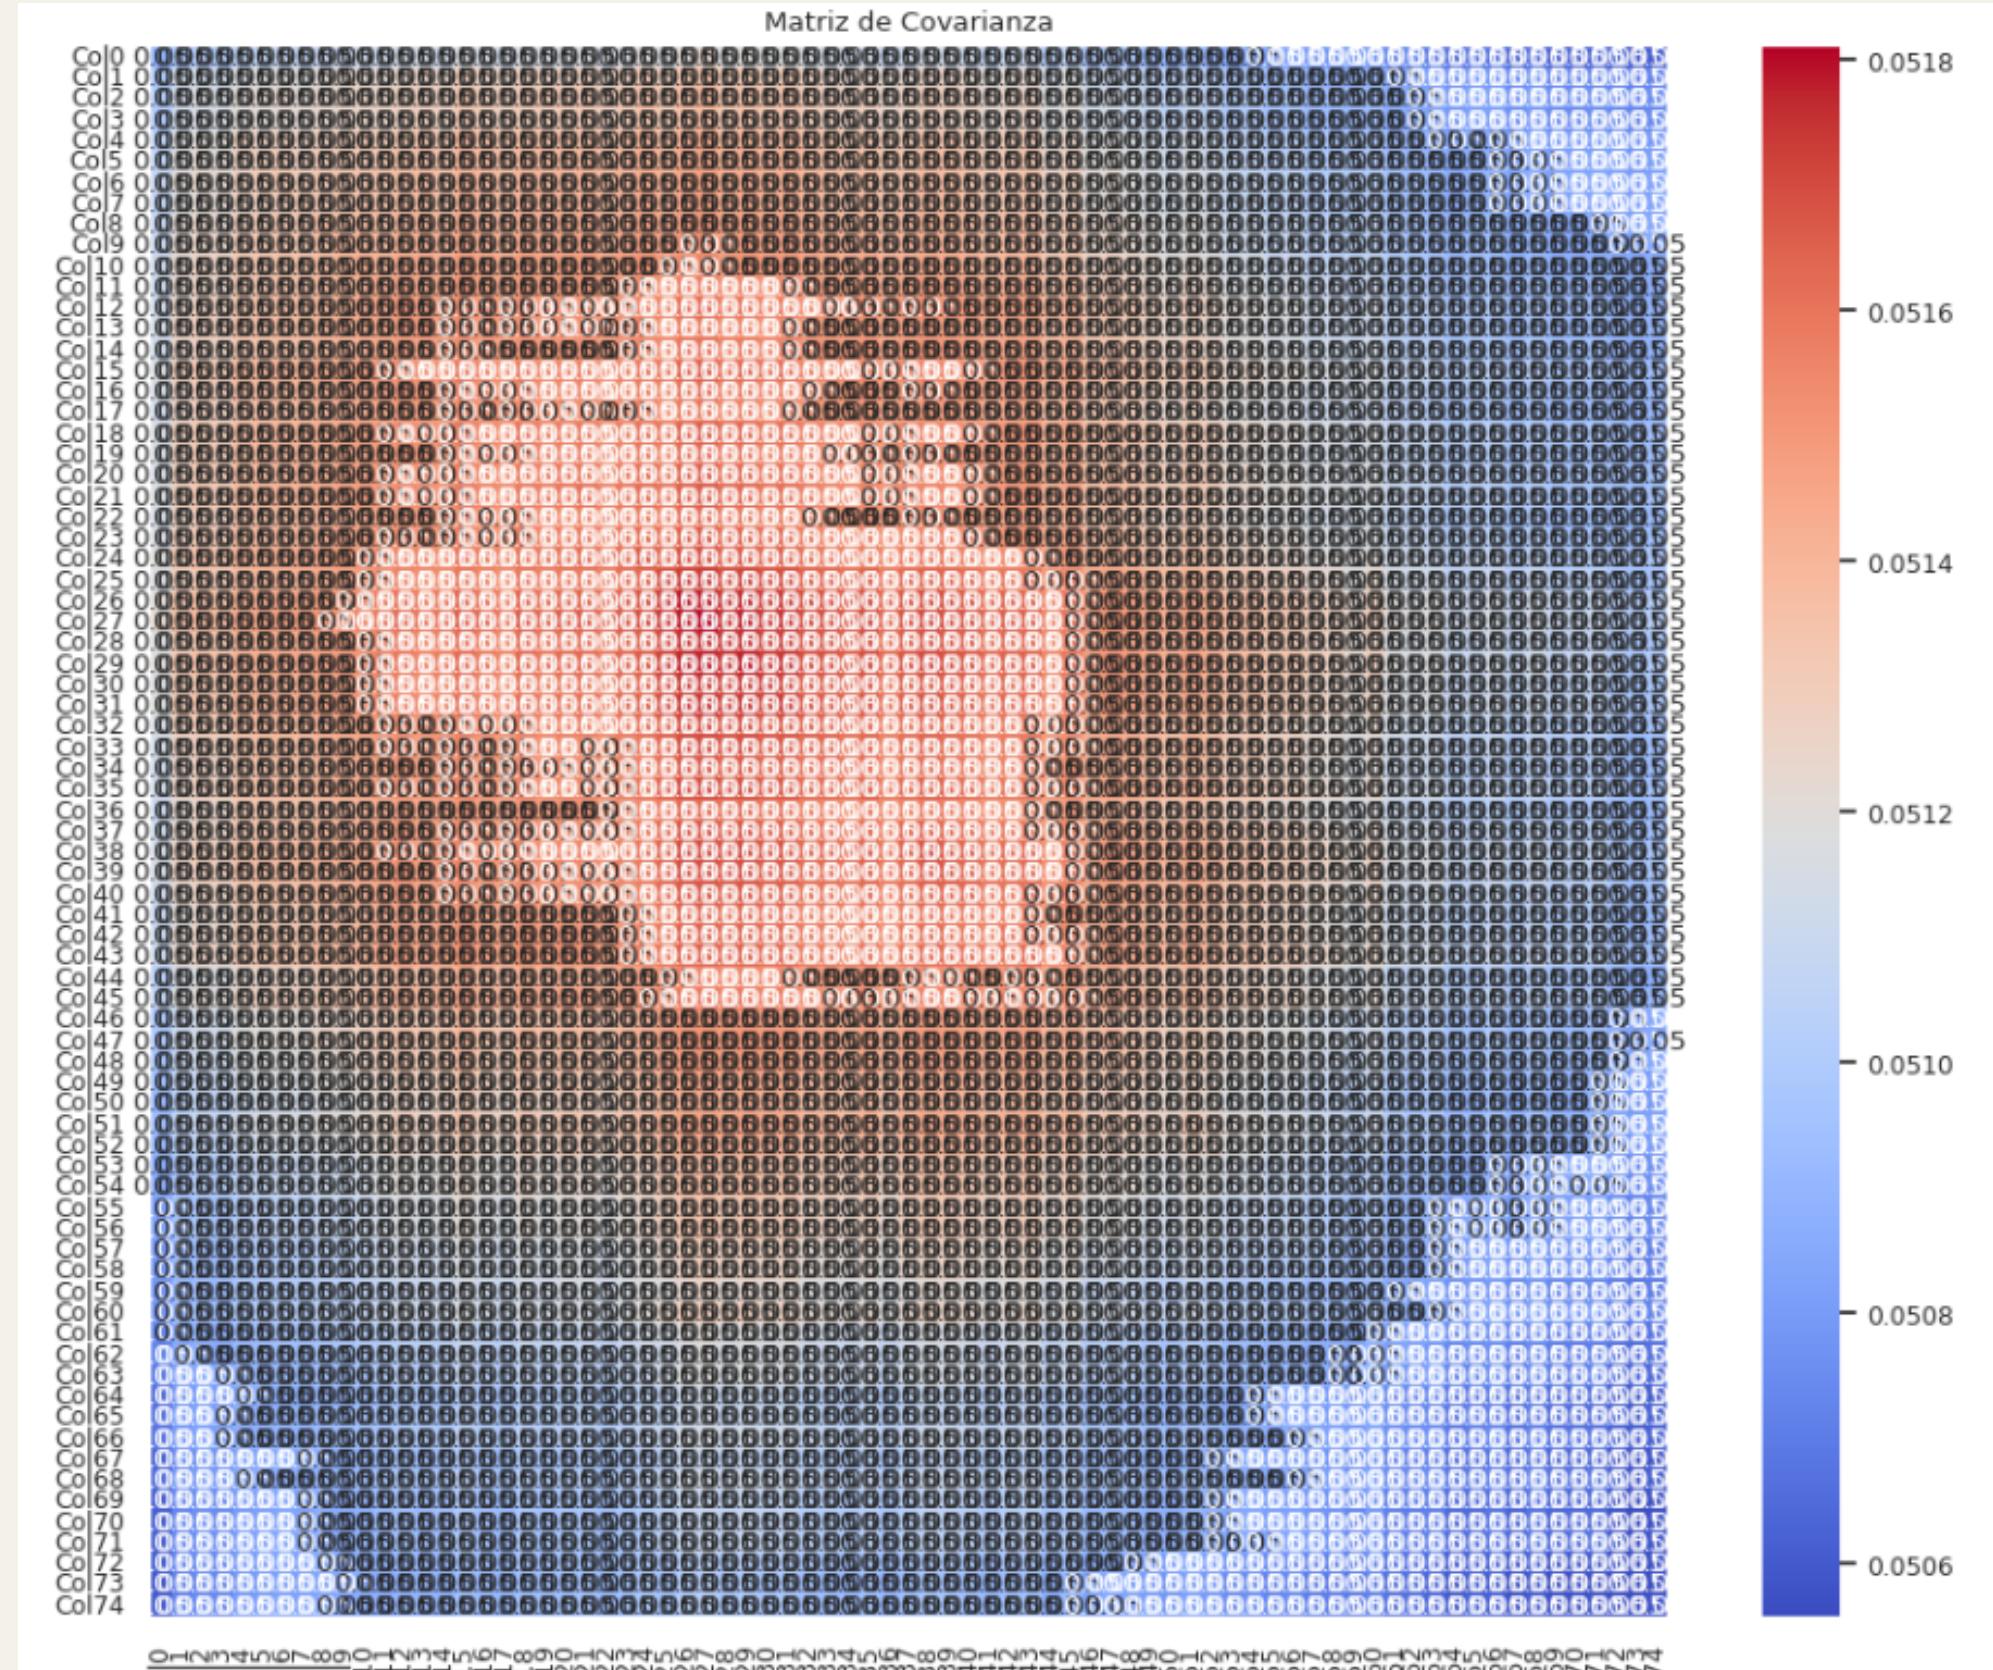


# RESULTADOS GENERALES

Metricas finales de los modelos				
Modelo	Accuracy	Precision	Recall	F1-score
Modelo 1	83%	88%	86%	84%
Modelo 2	82%	91%	79%	83%
Modelo 3	90%	92%	91%	90%
Modelo 4	91%	94%	91%	91%
Modelo 5	83%	92%	80%	83%
Modelo 6	91%	94%	92%	91%
Modelo 7	75%	100%	60%	75%
Modelo 8	93%	95%	93%	93%
Modelo 9	90%	93%	92%	90%
Modelo 10	91%	95%	91%	91%
Modelo 11	70%	-	-	-
Modelo 12	65%	-	-	-

# TRABAJO FUTURO

Para un trabajo futuro  
clasificaremos por  
medio de las  
covarianzas



GRACIAS!